

Ancre métriques éparses pour un a priori génératif 3D mono-vue : le verrou est le repère de sortie

Nom de l'auteur

Institut des Systèmes Intelligents et de Robotique (ISIR)
Sorbonne Université, Paris, France

auteur@isir.upmc.fr

Résumé—Un modèle génératif 3D mono-vue fournit un a priori de forme fort ; un robot fournit quelques mesures métriques — une poignée de contacts, une carte de profondeur. Nous demandons ce qui limite l'injection de mesures aussi éparses dans un a priori pré-entraîné, et trouvons que ce n'est ni leur nombre, ni leur contenu, ni la face de l'objet qu'elles touchent. C'est le *repère de sortie* du générateur. Sur un modèle de diffusion à latent d'ondelettes d'un milliard de paramètres, nous montrons que la pose de la forme générée n'est pas une fonction de l'image d'entrée : elle est rééchantillonnée avec la graine de bruit, et se déplace d'environ 135° en médiane d'une graine à l'autre sur 42 objets YCB. Deux voies d'ancrage sont ensuite mesurées contre ce fait. Injecter des contacts comme contrainte différentiable pendant l'échantillonnage, sans entraînement, améliore le F-Score@2% de +3,21 ($p = 3,1 \times 10^{-4}$, test des signes), contre +7,82 lorsque le repère est donné : l'estimation du repère consomme 59 à 74 % du gain atteignable, et, une fois le repère gelé, la passe ancrée est aussi reproductible que la passe non ancrée sur chaque objet testé. Ancrer le repère par conditionnement, en reprojétant une seule carte de profondeur dans les vues canoniques d'une variante multi-vues, fixe la pose à $\pm 2^\circ$ et gagne +11,2 en moyenne — mais l'effet est bimodal, perdant -22 sur les solides de révolution, et aucun sélecteur sans vérité terrain testé n'atteint les 72,2 qu'un oracle par objet obtient. Empiler les contacts sur le repère ancré ajoute +0,38. Sur sept manipulations contrôlées, ce qu'un jeu d'ancres exige est l'étalement spatial et la justesse du placement ; le nombre, les normales et la visibilité ne comptent pas, et des ancres sur la face que la caméra voit déjà valent autant que des ancres sur celle qu'elle ne voit pas. Cinq formulations de fusion alternatives qui traitent les mesures comme un générateur échouent toutes pour cette seule cause, que nous quantifions sans aucun modèle de diffusion : six contacts orientés reconstruits par Poisson atteignent 19,9 F@2 % contre 56,5 pour l'image seule.

I. INTRODUCTION

Les grands modèles génératifs 3D pré-entraînés reconstruisent un objet plausible à partir d'une image unique. Un robot qui tient cet objet sait des choses que l'image ne dit pas : où sont ses doigts, et la profondeur de ce que la caméra voit. La question naturelle est comment injecter ces mesures dans un modèle qui n'a jamais été entraîné à les recevoir.

Ce travail a commencé comme une étude du toucher — une poignée de contacts tactiles peut-elle améliorer une reconstruction mono-image — et son résultat central est que la question était posée sur le mauvais axe. Les contacts aident, modestement et significativement. Mais ce qui décide de combien ils aident n'a rien à voir avec les contacts : ni leur nombre sur une plage de $16\times$, ni la présence d'une normale, ni le fait qu'ils soient sur la face que la caméra ne voit pas. Ce qui

décide est de savoir si les mesures peuvent être placées dans le repère où le générateur produit sa forme — et ce repère, nous le montrons, n'est pas une fonction de l'entrée. Il est tiré avec le bruit.

Nous traitons donc le problème comme un problème d'*ancrage* d'un a priori par des mesures métriques éparses, et nous utilisons deux sources de mesure comme deux sondes du même verrou. Les contacts tactiles entrent comme contrainte différentiable appliquée pendant l'échantillonnage, sans entraînement. Une carte de profondeur unique entre comme signal de conditionnement, reprojétée dans les vues canoniques d'une variante multi-vues de la même ossature. La première ne peut pas fixer le repère et le paie ; la seconde le fixe, mais en tendant au modèle une preuve qu'il traite comme réelle, avec des conséquences qui dépendent de l'objet. Aucune n'est une solution. Les deux ensemble localisent le problème.

A. Contributions

- 1) **La pose de sortie d'un modèle de diffusion 3D mono-vue n'est pas apprenable depuis son entrée** : sur trois graines de bruit et la même image, elle se déplace d'environ 135° en médiane sur 42 objets, les objets asymétriques n'étant pas plus stables que les symétriques (Sec. III).
- 2) **Un schéma d'ancrage par contrainte sans entraînement**, différentiable de bout en bout à l'échantillonnage, et la mesure de ce que le repère lui coûte : +3,21 réalisés contre +7,82 repère donné (Secs. IV-A, VI-A).
- 3) **Un schéma d'ancrage par conditionnement** par reprojektion de profondeur, qui fixe le repère et gagne +11,2, avec le constat que le gain est bimodal et que le sélecteur sans vérité terrain évident échoue (Secs. IV-B, VI-B).
- 4) **Une caractérisation de ce qu'un jeu d'ancres doit être** : sept manipulations contrôlées montrent que l'étalement et la justesse du placement comptent, tandis que le nombre, les normales et la visibilité ne comptent pas (Sec. VI-C).
- 5) **Une décomposition de la variance** d'une exécution à l'autre, montrant que, repère gelé, le guidage n'ajoute aucune variance sur aucun de quatre objets, et que ce qui domine est donc la réestimation du repère, ainsi que trois pièges d'évaluation qui ont chacun renversé silencieusement une conclusion (Sec. VI-F).

II. TRAVAUX CONNEXES

Reconstruction de forme visuo-tactile. Les travaux antérieurs combinent les deux modalités soit en fusionnant des représentations apprises [7], [8], soit en accumulant des contacts denses dans une surface implicite [9]. Les deux supposent assez de données tactiles pour décrire une forme : [7] apprend une fusion par cartes à partir de touchers simulés sur un grand ensemble d’objets, et [9] intègre des relevés GelSight denses dans une surface implicite par processus gaussien. Notre régime est l’inverse. Une saisie avec une main à neuf zones rend un nombre de contacts à un seul chiffre, trop peu pour ajuster une surface ; leur valeur est d’être des ancrs sur un a priori, non un signal à reconstruire. La Sec. VI-D montre que les formulations qui les traitent en générateur échouent toutes pour une même raison.

Modèles génératifs 3D. Nous partons de WaLa [1], un modèle de diffusion à latent d’ondelettes d’un milliard de paramètres qui prédit directement $\hat{z}_0$ et le décode en champ de distance signée 256^3 . Sa variante mono-vue est notre ossature principale ; sa variante à quatre vues de profondeur est le véhicule de la Sec. IV-B. Nous ne réentraînons rien.

Guidage dans les modèles de diffusion. Le guidage par classifieur [2] et le guidage sans classifieur [3] orientent l’échantillonnage vers une condition. Notre schéma par contrainte est le plus proche du premier par l’esprit, mais n’utilise aucun classifieur : la correction est le gradient analytique d’un résidu géométrique, donc sans paramètre appris ni distribution d’entraînement à quitter.

Génération conditionnée par la pose. Zero-1-to-3 [4] conditionne sur une transformation caméra relative explicite ; les méthodes stéréo par passe avant comme DUS3R [5] régressent la pose directement depuis une paire d’images. Une initialisation façon SDEdit [12] offre une troisième voie, que nous discutons sans la tester. La Sec. III explique pourquoi aucune n’est un correctif immédiat ici : l’ossature mono-vue ne reçoit aucune information de caméra, et les variantes qui en reçoivent détruisent précisément la marge que les mesures devaient combler.

III. LE REPÈRE DE SORTIE N’EST PAS UNE FONCTION DE L’ENTRÉE

Les mesures vivent dans le repère du capteur ; le générateur produit dans un repère canonique qui lui est propre. Tout schéma d’ancrage doit envoyer l’un sur l’autre. Avant de demander avec quelle précision, nous demandons si la cible de cette application existe.

La cause, en une ligne de configuration. L’ossature mono-vue déclare `use_camera_index = False` : la fonction qui extrait l’indice de vue renvoie `None`, et le modèle ne reçoit aucune information sur la caméra. Il n’y a donc aucune convention de repère à retrouver ; la pose de sortie est ce que le contenu de l’image et le bruit produisent.

La pose est rééchantillonnée avec le bruit. Le correctif le moins coûteux imaginable serait de régresser la rotation de sortie depuis l’image, sans réentraîner le générateur. Il présuppose que la pose soit une fonction de l’image. En

comparant les rotations obtenues pour trois graines de bruit sur la *même* image, sur 42 objets, l’écart médian entre graines vaut $136,5^\circ \pm 3,7$ pour les objets asymétriques et $135,7^\circ \pm 3,7$ pour les symétriques, moyenne et écart-type sur quatre exécutions indépendantes du recalage ; dans chacune, 1 objet asymétrique sur 16 est stable sous 30° et 0 sur 26 chez les symétriques ; la corrélation asymétrie / stabilité vaut $-0,14 \pm 0,06$. Le recalage échantillonne des points au hasard, et sur un solide de révolution la rotation qu’il trouve est arbitraire, d’où la dispersion des médianes ; la conclusion au niveau de la partition, elle, ne bouge pas — les comptes d’objets stables et l’absence de toute relation asymétrie–stabilité sont identiques dans les quatre exécutions. (La mesure d’asymétrie par objet est elle-même stable à 0,001 ; un objet est posé sur le seuil de 0,02 et change de côté dans une exécution sur quatre, donnant 17/25.) Le partage par symétrie écarte un artefact de mesure — deux sorties identiques d’un solide de révolution se recalent avec des rotations très différentes — et les objets asymétriques, dont l’orientation est identifiable, ne sont *pas plus stables*. Aucun régresseur ne peut apprendre cette pose : non faute du bon estimateur, mais parce que la cible n’existe pas.

Les modèles qui reçoivent la pose l’ancrent. Les variantes multi-vues de la même ossature déclarent `use_camera_index = True` et prennent quatre images avec leur indice dans un rig canonique à 55 positions. Leur rotation entre prédiction et référence est reproductible à $0,8^\circ$ d’une graine à l’autre et identique sur tous les objets bien contraints. Mais quatre vues résolvent aussi la reconstruction — jusqu’à 99,9 F@2 % sur des objets que le mono-vue note entre 23 et 59 — ne laissant rien à ajouter à une mesure. **Pose et marge ne coexistent dans aucune variante publiée.** C’est la tension que les deux voies d’ancrage ci-dessous doivent négocier.

IV. DEUX FAÇONS D’ANCER

A. Ancrage par contrainte pendant l’échantillonnage

L’ossature prédit directement $\hat{z}_0$ plutôt que le résidu de bruit : la sortie du réseau *est* donc l’estimation de forme courante, et peut être corrigée sans toucher au calendrier de bruit ni à l’échantillonneur. À chaque pas, nous décodons $\hat{z}_0$ en champ de distance signée dense $\Phi(\hat{z}_0) \in \mathbb{R}^{256^3}$, l’évaluons aux N points d’ancrage p_i , et avançons selon le gradient de

$$\mathcal{L}_{\text{pos}} = \frac{1}{N} \sum_{i=1}^N \left[\mathcal{T}(\Phi(\hat{z}_0), p_i) \right]^2, \quad (1)$$

où $\mathcal{T}$ est l’interpolation trilineaire. La contrainte imposée est simplement *la surface passe par ces points* (Fig. 1). Le pas est normalisé, $\Delta = w \|\hat{z}_0\| \nabla \mathcal{L} / \|\nabla \mathcal{L}\|$, pour que le poids w ne dépende ni de l’échelle du champ ni de celle du latent, qui dérivent tous deux pendant l’échantillonnage.

Le guidage n’a jamais besoin du maillage, seulement du champ : les *marching cubes* [11] ne sont appliqués qu’une fois, à la fin, pour exporter le résultat. Point décisif : *aucune prédiction n’est jamais mélangée à une autre*. L’interférence




FIGURE 1. **L’ancrage par contrainte, à sa place.** La correction agit sur le $\hat{z}_0$ prédit à l’intérieur de la boucle de débruitage, à travers un décodage différentiable de bout en bout ; les ancres sont la seule grandeur mesurée du schéma (en vert). Les marching cubes sont hors de la boucle parce qu’ils ne sont pas différentiables — et le guidage n’a jamais besoin du maillage, seulement du champ. Aucune prédiction n’étant jamais mélangée à une autre, l’interférence destructive qui condamne les formulations par composition de la Sec. VI-D ne peut pas se produire.

destructive qui condamne les formulations par composition de la Sec. VI-D ne peut pas se produire.

Mise en œuvre. $\mathcal{T}$ est écrite à la main, en indexation et produits, plutôt qu’avec `grid_sample` : le noyau rétropropagé 3D de cette dernière n’est pas implémenté sur Apple Metal, et le repli CPU imposerait un aller-retour de 67 Mo par pas. Coût mesuré : 3,44 s par pas guidé, 8,98 Go de crête mémoire, ≈ 55 s par échantillon à 20 pas sur un M2 Max. Les poids de l’ossature sont utilisés tels quels, mais son code n’est pas celui publié. La faire tourner sur Metal a demandé de convertir des tenseurs float64 en float32 à plusieurs endroits et de compiler nativement la bibliothèque de convolutions éparses ; une rétropropagation à travers le modèle ne tient en mémoire qu’avec du *gradient checkpointing* sur le transformeur de diffusion (crête 21 $\rightarrow$ 6,5 Go) ; et trois pull requests du dépôt public y sont fusionnées. Le guidage, lui, enveloppe le débruiteur au moment de l’échantillonnage et ne modifie ni l’échantillonneur ni les poids. Les campagnes d’ancrage rapportées ici ont toutes tourné sur ce portage, et aucune n’a été recoupée avec l’implémentation CUDA de référence. Le code modifié est publié avec l’article, accompagné d’une notice qui liste ces changements comme l’exige la licence de l’ossature.

Terme optionnel de normale. Un contact venant d’une main porte une normale sortante approchée n_i . Nous n’imposons que la *direction* du gradient du champ, $\mathcal{L}_{\text{nm}} = \frac{1}{N} \sum_i [1 - s g_i \cdot n_i / \|g_i\|]$ avec $g_i = \nabla_p \Phi|_{p_i}$ par différences finies centrées et $s = +1$ la convention de signe mesurée (extérieur positif : médiane intérieure $-0,0998$, extérieure $+0,0999$, une TSDF tronquée à $\pm 0,10$). Les deux pertes ont des unités incommensurables ; λ est calibré une fois au premier pas guidé pour que leurs normes de gradient coïncident, puis figé. La Sec. VI-C montre que le terme n’aide pas de façon mesurable.

Placer les ancres. Sans vérité terrain, le repère est estimé par deux critères : la *cohérence de silhouette* (projeter la prédiction et la comparer à l’image de conditionnement, que le modèle a déjà reçue) et le *résidu des ancres* (parmi les poses que la silhouette laisse plausibles, garder celle dont les ancres s’approchent le plus de la surface de la première passe). Aucun ne suffit seul. Recaler les ancres sur une première passe non guidée par ICP les place, comparées à leur position exacte, à 0,66–0,76 en médiane dans un repère où l’objet occupe $[-1, 1]$ — sur la surface mais *au mauvais endroit*, l’ICP superposant sans respecter les correspondances et les quasi-symétries lui en laissant la latitude. Silhouette plus résidu ramènent l’écart médian de 0,755 à 0,501, et à 0,111 sur les objets sans ambiguïté de silhouette.

B. Ancrage par conditionnement à travers une variante multi-vues

La variante à quatre vues de profondeur ancre le repère mais exige quatre entrées, et quatre vues réelles ne laissent aucune marge. Fournir une vue réelle et trois images vides échoue : mesuré sur quatre objets et deux graines, 43,07 F@2 % contre 95,40 avec quatre vues réelles, et moins bien que le modèle mono-vue dédié sur la moitié des objets. **Les vues vides ne sont pas neutres ; elles retirent de l’information.**

Une carte de profondeur, en revanche, est de la géométrie 3D dans le repère de la caméra. On peut la rétroprojeter en points, puis la revoir depuis n’importe quelle autre position du rig canonique. La vue synthétique est géométriquement juste là où elle a de la donnée et vide ailleurs — bien plus proche de la distribution d’entraînement qu’une image noire. Nous fournissons donc au modèle *une vue de profondeur réelle et trois reprojetées depuis elle*, avec leurs quatre indices de caméra. Le placement des ancres devient alors une transformation fixe, calibrée une fois : mesuré sur quatre objets et deux graines,

la rotation de sortie reste entre 118° et 122° autour d’un axe constant.

L’intention de conception était que la reprojection *n’ajoute aucune information* — la même observation unique réencodée — pour que la reconstruction reste au niveau mono-vue pendant que les indices de caméra ancrent la pose. La Sec. VI-B montre que cette intention n’a pas été atteinte : le modèle traite les vues reprojctées comme des preuves, et ce qu’il fait de leurs trous dépend de l’objet.

C. Modèle d’ancres

Échantillonner les ancres uniformément sur le maillage de référence est l’objection la plus lourde contre tout résultat d’ancrage, puisque les points viennent alors de la réponse. Nous le remplaçons par un modèle de palpation imposant trois contraintes physiques : accessibilité en ligne droite (rayons lancés depuis l’extérieur, premiers impacts seuls), restriction à la face cachée de la caméra (une caméra placée dans le mauvais repère : 61 % de ces ancres seulement sont cachées de celle qui a rendu l’image, voir les limites), et rejet des points où une pulpe de 6 mm ne passerait pas. Les ancres sont regroupées en *sites* plutôt que dispersées — une main touche par plaques. Ce seul changement divise par deux le plafond de la méthode (+14,37 → +6,77 sur cinq objets) : une partie du gain annoncé par les campagnes intermédiaires venait de la couverture uniforme, pas des mesures.

Pour la Sec. VI-E, nous utilisons en outre un *simulateur de préhension* qui place une ancre par zone de doigt (pouce, index, majeur, annulaire, auriculaire, paume) à des angles anatomiques fixes autour de l’axe principal de l’objet, bien plus proche d’une main réelle que des sites bien répartis : écart minimal entre ancres de 0,058 à 0,344 contre 0,446 à 1,281 pour nos sites.

V. PROTOCOLE EXPÉRIMENTAL

Protocole. 42 objets YCB [6], 3 graines de bruit chacun, soit 126 comparaisons *appariées* : chaque génération ancrée est comparée à une génération non ancrée de *même graine*. Rien n’étant entraîné, tous les objets sont des objets de test.

Métrique. F-Score@2% après recalage sur la référence, distance de Chamfer symétrique et connectivité.

Significativité. Nous utilisons un **test des signes**, pas un test de Student : la distribution des gains est fortement asymétrique (médiane +1,69 pour une moyenne de +3,21) et quelques objets dominant. Une moyenne y est fragile, un compte de signes ne l’est pas. Tous les p sont **bilatéraux**, et les ex aequo exacts sont écartés plutôt que comptés comme des échecs — un cas sur 126 est noté à l’identique avec et sans ancrage, d’où un résultat principal rapporté sur 125.

Discipline de l’oracle. Là où c’est indiqué, les ancres sont placées à l’aide du maillage de référence, tirées avec le modèle de palpation de la Sec. IV-C. Ces chiffres sont rapportés *uniquement* comme bornes supérieures, jamais comme performance de système, et toujours avec mention explicite de ce qui a été donné gratuitement.

TABLE I
ANCRAGE PAR CONTRAINTES AVEC DES CONTACTS TACTILES, 42 OBJETS YCB.

Témoin non ancré (image seule)	53,1 F@2 %
Gain moyen, repère estimé	+3,21
Médiane / écart-type	+1,69 / 7,52
Cas positifs	83 / 125
Test des signes (bilatéral)	$p = 3,1 \times 10^{-4}$
Objets à gain moyen positif	35 / 42
Gain moyen, repère donné (oracle)	+7,82

TABLE II
LES DEUX VOIES D’ANCRAGE, ET LEUR COMBINAISON. MÊMES 42 OBJETS, MÊMES 126 CAS APPARIÉS PAR GRAINE, MÊME MÉTRIQUE.

	F@2 %	repère
Image seule (ossature mono-vue)	53,1	tiré avec le bruit
+ contacts en contrainte	56,3	estimé, $\pm$ large
Profondeur reprojctée en 4 vues	64,3	fixé, $\pm 2^\circ$
+ contacts en contrainte	64,7	fixé
Choix oracle de la voie, par cas	72,2	—
Quatre vues de profondeur <i>réelles</i> (4 objets)	98,6	fixé

VI. RÉSULTATS

A. Ancrage par contrainte : ce que le repère coûte

Le tableau I donne le résultat par contrainte. L’effet est modeste au regard de sa dispersion : c’est la significativité du *signe* qui est solide, pas la précision de l’amplitude. Sur cinq objets, une campagne antérieure mesurait +1,79 à $p = 0,035$; à 42 objets l’effet est plus fort et deux ordres de grandeur plus significatif — ce n’était donc pas un objet qui portait tout.

Comparer le gain réalisé à l’oracle isole le coût de l’estimation du repère : +3,21 contre +7,82 sur 42 objets, et +1,79 contre +6,77 sous le modèle de palpation sur cinq. **L’estimation du repère absorbe 59 à 74 % de ce que l’ancrage par contrainte peut rendre** — un ordre de grandeur au-dessus de tout autre facteur mesuré dans ce papier.

B. Ancrage par conditionnement : le repère fixé, à un prix

Le tableau II place les deux voies côte à côte. Reprojecter une seule carte de profondeur dans les quatre vues canoniques gagne +11,22 sur l’ossature mono-vue en moyenne appariée — plus de trois fois ce que les contacts rendent — et fixe le repère. Mais le gain est **bimodal** : 87 cas sur 126 s’améliorent de +26,1 en moyenne, et 39 cas perdent −22,1. Les pertes sont catastrophiques sur les solides de révolution — balle de baseball 95,5 → 29,2, ballon 93,9 → 35,5, conserve 91,0 → 46,8 — où une seule vue de profondeur laisse trois vues canoniques presque vides, que le modèle remplit depuis son a priori, mal. L’intention de la Sec. IV-B, que la reprojection *n’ajoute aucune information*, n’a pas été atteinte : le modèle traite les vues reprojctées comme des preuves.

Aucun sélecteur sans vérité terrain testé n’atteint l’oracle. Un choix par cas entre les deux voies atteindrait 72,2. Le sélecteur évident — la part de pixels reprojctés qui portent une profondeur — est *anti-corrélé* au gain ($r = -0,40$) : les

objets compacts et ronds remplissent beaucoup de pixels et échouent, les objets plats en remplissent peu et réussissent. Le remplissage mesure la forme de l'objet, pas la qualité de la reprojection, et aucun seuil ne bat le choix systématique de la reprojection. La classification par symétrie, l'autre candidat, est déjà réfutée comme prédicteur en Sec. VI-C. Le 72,2 existe mais est hors de portée sans connaître la réponse.

Empiler les contacts sur le repère ancré ajoute +0,38 (75/126 positifs, $p = 0,040$). Une fois le repère fixé et l'a priori fort, les contacts n'ont plus grand-chose à corriger. Les deux voies ne sont pas complémentaires non plus : la corrélation entre le gain de reprojection et le gain de contacts vaut +0,056, et sur les 39 cas où la reprojection échoue, les contacts récupèrent +1,7 contre une perte de -22. Elles échouent sur des objets différents par accident, pas par conception.

C. Ce qu'un jeu d'ancres exige

La Fig. 2a balaie sept propriétés du jeu d'ancres sous ancrage par contrainte, sur cinq objets, placement oracle. Trois passent un test des signes bilatéral à $p = 0,035$, et elles partagent un thème.

L'étalement compte. À budget constant de 128 ancres réparties sur N sites, le gain vaut -0,42 à 4 sites, +1,79 à 8, +2,03 à 16 et +1,55 à 32 : un seuil entre 4 et 8, puis un plateau. Passer de 8 plaques à 4 coûte -2,55 (12/15 négatifs).

La justesse du placement compte. Un bruit gaussien de 3 mm en position et 15° sur les normales, l'ordre de ce que la cinématique directe d'un doigt fournirait, coûte -2,40 (12/15 négatifs).

Le nombre ne compte pas. De 32 à 512 ancres, le gain vaut +0,23, +1,21, +0,07 : plat sur une plage de $16\times$.

Les normales ne comptent pas. Les ajouter donne +0,93, que le test des signes ne sépare pas de zéro (10/15, $p = 0,302$). La moyenne est portée par deux valeurs aberrantes : retirer la plus grande laisse +0,43, pour une médiane de +0,26.

La visibilité ne compte pas — et c'est le résultat qui renverse la prémisse. Avec le simulateur de préhension, trois stratégies placent les mêmes six ancres avec 87 %, 60 % et 30 % d'entre elles sur la face cachée de la caméra. Leurs gains valent +1,37, +1,73 et +2,55 : la stratégie qui touche le *moins* la face cachée gagne le *plus*, sans que le test des signes en sépare aucune (11/15, $p = 0,118$ entre les deux dernières). Cas par cas, sur 45 cas, la corrélation entre part cachée et gain vaut $r = -0,001$ (Fig. 2b) : le nombre d'ancres que la caméra ne voit pas ne dit rien du gain. Les ancres éparées ne complètent pas ce que la vision manque. **Elles fixent position, échelle et orientation globales d'un a priori dont le repère est lâche, et pour cela le côté où elles se trouvent n'importe pas.**

D. Pourquoi les formulations de fusion échouent

Cinq formulations exigent que les mesures produisent une forme complète, ensuite mélangée à celle de l'image. L'échec le plus instructif est le mélange pondéré dans l'espace $\hat{z}_0$, qui s'effondre de 44,9 à 13,9 F@2 % à poids égal : l'interpolation convexe entre deux modes distincts d'une distribution tombe

TABLE III
SIX CONTACTS ORIENTÉS, AVEC ET SANS A PRIORI GÉNÉRATIF. LES VALEURS POISSON SONT MOYENNE $\pm$ ÉCART-TYPE SUR CINQ EXÉCUTIONS.

Reconstruction de Poisson [10], 6 contacts orientés	19,90 $\pm$ 0,36 F@2 %
Reconstruction de Poisson, 18 contacts (3 prises)	20,44 $\pm$ 0,18
A priori génératif, image seule, sans mesure	56,52

TABLE IV
CARDINALITÉ RÉALISTE, PLACEMENT ORACLE. DIFFÉRENCES APPARIÉES EN BAS.

Condition	Gain moyen	Test des signes
8 ancres, position seule	+3,25	$p = 0,118$
8 ancres + normales	+4,18	$p = 0,118$
8 ancres, placement bruité	+1,78	$p = 0,302$
4 ancres seulement	+0,70	$p = 1,000$
<i>Différences appariées (même objet, même graine)</i>		
Normales vs sans	+0,93	$p = 0,302$
Bruit de placement 3 mm / 15°	-2,40	$p = 0,035$
4 zones au lieu de 8	-2,55	$p = 0,035$

dans une zone de faible densité — le point médian entre deux formes plausibles n'est pas une forme plausible. Cela vaut pour tout mélange naïf de latents génératifs.

Le tableau III convertit la cause commune en une mesure, sans aucun modèle de diffusion. La reconstruction de Poisson consomme précisément des points orientés et rend une surface fermée dans 9 cas sur 10 — ce n'est pas du gravier. Elle n'atteint pourtant que 35 % de ce que l'image seule obtient déjà. Les mesures éparées sont un mauvais générateur et une bonne ancre ; la répartition des rôles n'est pas un choix de conception mais ce que les données imposent.

Un module de fusion *appris* (encodeur de géométrie et cross-attention greffés sur l'ossature gelée, 50 époques, 5 à 10 M de paramètres entraînés) mesure -4,20 sur cinq objets en tirages non appariés — 0,9 erreur type, indiscernable de zéro. La comparaison avec l'ancrage par contrainte ne porte pas vraiment sur les deux scores, tous deux médiocres. Elle porte sur le fait que la voie apprise **consomme les objets dont elle aurait besoin pour se juger** : 15 sur 20 deviennent des données d'entraînement, il en reste cinq pour conclure, avec un bruit non apparié quatre fois plus grand. Dans un régime à peu de données et à métrique bruitée, une méthode sans entraînement achète de la *puissance statistique*, et c'est ce qui a décidé cette étude.

E. Ce qui subsiste à la cardinalité matérielle

Une main dextre à neuf zones n'en excite que trois à cinq dans une saisie réelle. À une ancre par zone (tableau IV), une réduction d'un facteur 16 par rapport à la campagne de référence coûte environ la moitié du plafond (+6,77 $\rightarrow$ +3,25), pas la totalité. Mais les deux effets qui atteignent la significativité sont précisément les deux propriétés d'une prise réelle : le bruit de placement et la réduction du nombre de zones. Une vraie main a les deux, et la condition conjointe — ancres resserrées du simulateur, avec normales, bruit de




FIGURE 2. **Sept manipulations contrôlées du jeu d'ancres.** (a) Chaque estimation est une différence appariée entre deux conditions ancrées, sur le même objet et la même graine de bruit ($n = 15$). Les barres d'erreur valent une erreur type — 0,58 lorsque les deux conditions viennent de la même campagne et partagent donc le repère oracle, le bruit de placement s'annulant alors dans la différence (poolé sur quatre objets), et au moins 0,91 lorsqu'elles viennent de campagnes distinctes, qui ne partagent aucune passe non ancrée (mesuré sur un objet). La couleur marque la significativité au test des signes bilatéral, dont les comptes figurent à droite; nous nous appuyons sur lui plutôt que sur les erreurs types, car il ne demande aucune estimation de σ . Trois comparaisons seulement en sortent, et toutes trois portent sur *où* sont les ancres et *avec quelle justesse* elles sont placées — jamais sur leur nombre, ni sur ce que la caméra en voit. (b) Le résultat de visibilité seul, sur les 45 cas de la campagne de stratégies de préhension, la visibilité étant décidée depuis la caméra qui a rendu les images. L'ajustement par moindres carrés est plat.

placement *et* repère estimé plutôt qu'oracle — n'a pas été mesurée. Nous consignons la prédiction, avant mesure, qu'elle sera nulle.

F. Résultats méthodologiques

La variance d'une exécution à l'autre, et d'où elle vient. Relancer huit fois une commande identique — même objet, même graine, mêmes ancres — donne un écart-type de 0,49 pour la passe non ancrée mais 2,29 pour la passe ancrée, et 2,50 pour la différence appariée. La lecture évidente, selon laquelle le guidage amplifierait le non-déterminisme du GPU, est *fausse*, et nous la rapportons parce que nous l'avons d'abord tenue pour vraie. Ces répétitions ne sont pas identiques : le repère oracle est réestimé depuis la passe non ancrée de chaque répétition, si bien que les positions d'ancres bougent. Geler le repère sépare les causes :

	repère réestimé	repère gelé
non ancré	0,49	0,68
ancré	2,29	0,70
différence appariée	2,50	1,29

Le placement figé, la passe ancrée est aussi reproductible que la passe non ancrée (0,70 contre 0,68) : sur cet objet, **91 % de la variance d'un score ancré vient de la réestimation du placement des ancres**. Refaire la mesure à repère gelé sur trois objets de plus donne des écarts-types ancrés de 1,74, 0,40 et 2,56 contre 2,53, 0,49 et 2,19 non ancrés — la passe ancrée n'est jamais plus bruitée que la passe non ancrée, sur aucun objet. **Le guidage n'amplifie rien**. Ce qui varie, c'est l'objet : le plancher va de 0,40 à 2,56 sur les quatre, un facteur six. Une bonne part vient de la notation, pas du générateur. Noter quatre fois chaque maillage enregistré, sans rien régénérer, donne des écarts-types de 0,33 à 2,23 selon l'objet. Regroupée sur les

quatre, la notation seule a un écart-type de 1,45 quand un score ancré en a 1,60, et de 1,03 quand un score non ancré en a 1,72 : le recalage comme le F-Score échantillonnent des points au hasard, et l'ICP tombe parfois dans un autre bassin, jusqu'à 8 points d'écart sur un même maillage. À repère gelé, la génération elle-même ajoute peu (au plus 0,66, par différence). Nos erreurs types viennent de notations uniques et incluent donc ce bruit; moyenner plusieurs notations par prédiction les réduirait. Le problème de repère de la Sec. III apparaît donc deux fois : il consomme l'essentiel du gain moyen, et il domine la variance.

Cela corrige le modèle d'erreur. Au sein d'une campagne, le repère oracle est calculé une fois par (objet, graine) et partagé par toutes les conditions : le bruit de placement s'annule dans les différences entre conditions; entre campagnes il ne s'annule pas, aucune ne partageant sa passe non ancrée. Poolé sur les quatre objets, le σ à repère gelé d'un score ancré vaut 1,60, ce qui met l'erreur type intra-campagne d'une différence appariée à 0,58 sur 15 cas; le chiffre inter-campagnes, 0,91, n'a été mesuré que sur un objet et est une borne inférieure (Fig. 2a). Sous ces valeurs, les deux dégradations sont à 4 erreurs types et plus, et les deux effets que le test des signes rejette — normales, visibilité — entre 1,4 et 1,6. Nous fondons néanmoins chaque affirmation sur le test des signes, qui ne demande aucune estimation de σ et rend le même verdict.

Le F-Score est aveugle à la fragmentation. Un semis d'éclats disjoints près de la vraie surface obtient un bon score. Sur la banane : une entrée à 128 points produit 43 composantes connexes dont la plus grosse porte 11 % des faces, et 47,83 F@2 %, contre 34,48 pour une prédiction image seule qui est une surface fermée unique. Nous rapportons le nombre de composantes et rejetons les métriques de distance en deçà d'un seuil sur la part de la plus grosse.

Le F-Score est aveugle aux symétries miroir. Construire les candidats de recalage à partir de bases issues d'une SVD donne des repères orthogonaux mais pas nécessairement directs : **5 recalages sur 15 étaient des symétries.** Corrigé en forçant le déterminant à +1.

Un ICP mal initialisé échoue en silence. Un ICP initialisé à l'identité laisse le recalage hors de son bassin de convergence, sous-notant un objet de jusqu'à 31 points sans aucun signal d'erreur. Cela a modifié le classement entre méthodes comparées, et c'est l'origine du verdict initial à $n - 8$ points z du module appris.

VII. LIMITES

Le contrôle manquant. Le résultat de visibilité dit que des ancrs sur la face visible valent autant que des ancrs sur la face cachée. La face visible est exactement ce qu'une caméra de profondeur mesure. L'expérience qui en découle — remplacer les contacts tactiles par une poignée de points de profondeur de la face visible, en contraintes dans l'Éq. (1) — n'a pas été menée. Si elle donne le même +3, la voie par contrainte n'a besoin d'aucun toucher ; si elle donne moins, les contacts portent quelque chose de spécifique. Les deux réponses se publient, et nous n'avons ni l'une ni l'autre.

Une caméra placée dans le mauvais repère. L'importateur OBJ de Blender tourne chaque maillage Y-up dans son monde Z-up, $(x, y, z) \mapsto (x, -z, y)$, avant que la caméra en $(2, 2; -2, 2; 1, 8)$ ne le rende. Tous les calculs d'occultation ont placé cette caméra dans le repère propre du maillage, à 68° de celle du rendu : projetées depuis là, les silhouettes de référence recouvrent les images d'entrée à 0,51 en moyenne sur 42 objets, contre 0,95 avec la rotation, et l'étiquette visible/cachée diffère sur 26 % de la surface. Nous l'avons trouvé tard. Les parts cachées des stratégies de préhension et la Fig. 2b sont recalculées depuis la caméra du rendu ; depuis la caméra mal placée, la corrélation valait $-0,145$ et trois cas semblaient ne laisser aucune ancre sur la face cachée. Deux artefacts gardent l'erreur. Les sites de palpation de la Sec. IV-C ont été restreints à la face cachée de la caméra mal placée : vus de la caméra du rendu, 61 % de leurs ancrs sont cachées (de 15 à 90 % selon l'objet), un jeu majoritairement caché plutôt qu'un jeu de face cachée. Et la partition du rappel visible/occulté, sur laquelle aucune affirmation ne repose, n'est pas fiable. Un défaut plus petit s'y ajoute : le rendu normalise les objets à une dimension maximale de 1,3 quand le code d'occultation utilise 2,0 ; caméra corrigée, il change l'étiquette de 3 des 45 cas de préhension.

Les images sont des rendus Blender synthétiques, sous une seule position de caméra et un seul éclairage. Les ancrs sont échantillonnés sur le maillage de référence — filtrées par accessibilité, occultation et encombrement du doigt, mais sans bruit et jamais fausses, sauf là où du bruit est ajouté délibérément. Aucun objet, capteur ou robot réel n'intervient, bien que le banc robotique qui a motivé ce travail existe et soit opérationnel. Une seule famille d'ossature et un seul poids de guidage ont été utilisés ; trois graines par objet restent peu ; les expériences secondaires portent sur cinq objets, dont l'un, la

perceuse, porte une part importante de plusieurs totaux. Les formulations 3, 4 et 7 de la taxonomie de fusion sont *sans objet* dans ce régime de données plutôt qu'invalidées — le réentraînement à fusion précoce, seule voie que les auteurs de l'ossature valident, était hors budget.

VIII. CONCLUSION

Un a priori génératif 3D mono-vue peut être ancré par des mesures métriques éparses, et ce qui limite l'ancrage n'est pas les mesures. Leur nombre n'a pas d'effet sur une plage de $16\times$; leurs normales n'aident pas de façon mesurable ; qu'elles soient ou non sur la face que la caméra ne voit pas n'a pas d'effet non plus. Ce qui compte est de savoir si elles peuvent être placées dans le repère où le générateur produit — et ce repère est tiré avec le bruit, si bien qu'aucun estimateur ne peut l'apprendre. L'estimer malgré tout coûte 59 à 74 % du gain atteignable et explique ce qui varie d'une exécution à l'autre : repère gelé, l'ancrage n'ajoute aucune variance sur aucun de quatre objets.

Fixer le repère par conditionnement est possible, et vaut en moyenne trois fois plus que l'ancrage par contrainte, mais ce n'est pas gratuit : le modèle traite la preuve reprojetée comme réelle, et sur un tiers des objets le prix est catastrophique, sans sélecteur en vue qui ne connaisse déjà la réponse. Empiler des contraintes sur le repère fixé n'ajoute presque rien.

Le mécanisme cohérent avec tout cela n'est pas que les mesures complètent ce que la vision manque. C'est que *quelques ancrs vraies régularisent la sortie d'un a priori génératif* — position, échelle, orientation — et que le repère propre de l'a priori est ce qui fait obstacle. C'est une revendication plus modeste que celle que ce travail visait, et plus générale : elle vaut pour le toucher, pour la profondeur, et pour tout signal métrique épars qu'un robot peut apporter.

RÉFÉRENCES

- [1] A. Sanghi, A. Khani, P. Reddy, A. Rampini, D. Cheung, K. R. Malekshan, K. Madan et H. Shayani, *Wavelet Latent Diffusion (WaLa) : Billion-parameter 3D generative model with compact wavelet encodings*, *arXiv :2411.08017*, 2024.
- [2] P. Dhariwal et A. Nichol, *Diffusion models beat GANs on image synthesis*, dans *Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2021.
- [3] J. Ho et T. Salimans, *Classifier-free diffusion guidance*, dans *NeurIPS Workshop on Deep Generative Models*, 2021.
- [4] R. Liu, R. Wu, B. Van Hoorick, P. Tokmakov, S. Zakharov et C. Vondrick, *Zero-1-to-3 : Zero-shot one image to 3D object*, dans *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2023.
- [5] S. Wang, V. Leroy, Y. Cabon, B. Chidlovskii et J. Revaud, *DUST3R : Geometric 3D vision made easy*, dans *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2024.
- [6] B. Calli, A. Singh, A. Walsman, S. Srinivasa, P. Abbeel et A. M. Dollar, *The YCB object and model set : Towards common benchmarks for manipulation research*, dans *Proc. Int. Conf. Adv. Robot. (ICAR)*, 2015, p. 510–517.
- [7] E. J. Smith, R. Calandra, A. Romero, G. Gkioxari, D. Meger, J. Malik et M. Drozdal, *3D shape reconstruction from vision and touch*, dans *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 33, 2020.
- [8] E. J. Smith, D. Meger, L. Pineda, R. Calandra, J. Malik, A. Romero et M. Drozdal, *Active 3D shape reconstruction from vision and touch*, dans *Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2021.
- [9] S. Suresh, Z. Si, J. G. Mangelson, W. Yuan et M. Kaess, *ShapeMap 3-D : Efficient shape mapping through dense touch and vision*, dans *Proc. IEEE Int. Conf. Robot. Autom. (ICRA)*, 2022, p. 7073–7080.

- [10] M. Kazhdan et H. Hoppe, "Screened Poisson surface reconstruction", *ACM Trans. Graph.*, vol. 32, n° 3, 2013.
- [11] W. E. Lorensen et H. E. Cline, "Marching cubes : A high resolution 3D surface construction algorithm", dans *Proc. SIGGRAPH*, 1987.
- [12] C. Meng, Y. He, Y. Song, J. Song, J. Wu, J.-Y. Zhu et S. Ermon, "SDEdit : Guided image synthesis and editing with stochastic differential equations", dans *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2022.